

トヨタ関連企業 研究者データベースの構築状況

伊倉涼介

2026 年 8 月 17 日

1 本報告について

本共同研究 Science of Science の分析課題は、「誰が、どの論文を、誰と書いたのか」を網羅したデータベースを前提とする。本報告では、その構築状況と、構築を通じて分かった事項をまとめる。

2 データベースの構築状況

トヨタの三組織の公式サイトから論文一覧 919 件を自動で取得し、うち 852 件（92.7%）を OpenAlex に対応づけた（内訳は表 1。AISIN IMRA は日本法人と米国法人で別サイト）。

表 1 公式サイトから収集した論文と OpenAlex への対応づけ状況

収集元	収集件数	対応づけ済	対応率
豊田中央研究所	355	352	99.2%
AISIN IMRA（米国）	313	292	93.3%
トヨタ自動車未来創成センター	154	131	85.1%
AISIN IMRA（日本）	97	77	79.4%
合計	919	852	92.7%

DOI のある論文は完全一致で、ない論文はタイトルの類似度で対応づけた。文字列の一致だけでは誤同定が起りうるので、判断のつかない 10 件は目視で確認した。うち 9 件は同一の論文だったが、1 件は掲載誌も出版年も異なる別の論文だったため取り消した（表の 852 件は取消後）。対応づかなかった 67 件のうち 66 件は DOI を持たず、OpenAlex に未収録と見られる。

公式サイトに一覧のない AISIN IMRA 欧州法人については、Web of Science（大阪大学が契約する商用の文献データベース）を機関名で検索し、25 件を得た。同じ検索を米国法人とアイシン精機に対して行くと 833 件が該当し、うち 683 件は公式サイトに掲載がなかった。機関名で検索すれば、公式サイトの掲載漏れを補える。

被引用 24,786 件と参考文献 27,052 件も取得しており、指標の計算にそのまま使える。著者を研究者単位にまとめ直すと 1,249 名になり、うち 1,134 名（90.8%）の所属が分かった。さらにそのうち 574 名は、トヨタ関連企業に所属していることまで確認できている。

3 使用したデータベースとその使い分け

構築には四つの外部データベースを使った。どれに何を任せるかは、**著者を名前で検索するより、論文から引く方が安全である**という一点から決めている。著者名で検索すれば同姓同名が必ず混ざり、名前だけを手がかりにする限りこの曖昧さは解消できない。論文なら DOI で一意に定まる。どの論文かさえ確定していれば、そこから著者名や所属を取り出しても人物を取り違えることはない。つまり「この人物は誰か」という答えにくい問いを、「こ

の論文の著者は誰か」という確実に答えられる問いに置き換えている。

3.1 OpenAlex（無料） 論文の同定と指標計算の土台

OpenAlex は、論文の同定と、指標計算の土台になるデータ（被引用、参考文献、分野分類）の取得に使った。ただし**著者に振られた識別番号は使っていない**。同姓同名の別人が一つの番号にまとめられているためで、実例は第 4.3 節に挙げる。無料で取得できるのは 1 日 1,000 回までだが、1 回で 50 件をまとめて取れるので実質 1 日 5 万件になり、今回の規模なら足りる。

3.2 Crossref（無料） 著者名と ORCID の補完

著者名と ORCID は Crossref で補った。**AISIN IMRA 米国法人の 313 件は公式サイトに著者名の記載が一切なかったため、ここで埋めている**。ORCID は 383 名分を得た。第 4.3 節で述べるとおり、著者に紐づく識別子で信頼できるのは ORCID だけである。弱いのは所属情報で、Crossref に所属が載っていた論文は 34.5% しかない。出版社が登録した場合にしか入らないためである。この不足は Scopus で埋めた。

3.3 Scopus（大阪大学の契約） 論文を経由した所属の取得

著者の所属は Scopus から取った。ここでは途中で方針を変えている。その経緯が、本節冒頭の判断をそのまま裏づけている。当初は著者を名前で検索し、その著者に紐づく所属を直接得るつもりだった。これを二つの理由で断念した。まず、ORCID で検索しても、試した 6 名すべてで 0 件だった。Scopus 側に ORCID がほとんど登録されていないためである。次に、名前で検索しても同姓同名を絞り込めない。「Suzuki」という姓では **45,844 件** が該当し、名前だけでは一人に特定できない。

そこで、論文から所属を引く方式に切り替えた。どの論文かは確定しているので、人物の取り違えは起きない。所属が分かる論文の割合は **34.5% から 96.1%** へ上がり、Scopus にしか所属が載っていない論文も **394 件** あった。第 2 節で 1,134 名の所属が分かったのは、この方式による。

3.4 Web of Science（大阪大学の契約） 機関単位の探索

Web of Science だけは機関を単位に引いている。**返ってくるデータに所属の欄がないため、論文ごとに著者の所属を確かめる用途には使えない**。ただし機関名での絞り込みは効くので、機関単位で論文を洗い出す用途に限って使っている。第 2 節で述べた欧州法人の回収と、公式サイトに掲載漏れの補完がこれにあたる。予備的な検証では、著者名と機関名の組み合わせを所属の間接証拠に使えるかも試した。しかし **Scopus で見つからなかった所属を 1 件も新たに拾えなかったため、この用途からは外した**。

費用は、OpenAlex と Crossref が無料の範囲に収まり、Scopus と Web of Science は大阪大学の契約で賄える。追加の支出は生じない。

4 構築を通じて分かった事項

4.1 収録している年代がサイトによって大きく異なる

出版年が 2018 年以降の論文の割合は、未来創成センターが 98.5%、豊田中央研究所が 99.4% と高い。これに対して AISIN IMRA 米国法人は 17.8%（中央値 2006 年、292 件中 62 件は 2000 年より前）、日本法人は 51.9%、全体では 67.0% である。対象期間の取り方しだいで、どの組織のデータがどれだけ残るかが変わる。

4.2 受領した著者リストは裏付けの取れる割合が高くない

受領した著者リスト（Sota Hayashi 氏より 9,429 名分、OpenAlex 由来）から 100 名を選び、Scopus（商用の文献データベース）と Web of Science で照合した。裏付けの取れた割合は、異常なキャリア長の群が 30.0%、「トヨタ自動車のスイス法人」と登録された組織の群が 48.6%、対照群が 62.9% だった。スイス法人の群では、11 名（31.4%）が実際には東京大学や三菱総合研究所などに所属しており、抽出元によっては母集団として使えない。

4.3 著者の識別番号が信頼できないため、名寄せの誤り率を実測した

受領リストの精度が伸びない原因もここにある。同一人物が複数の表記で現れるため、これを一人にまとめる処理（名寄せ）が最も難しい。受領リストが用いているのと同じ OpenAlex の著者識別番号は**信頼できない**。同姓同名の別人が一つの番号にまとめられており、「S. Nakamura」は研究歴が 74 年に及ぶ。Web of Science の研究者識別番号も同じで、2022 年発行の番号に 1970 年代の論文が結びついている。研究歴が異常に長い著者はこの集約が原因なので、除外はせず、複数の人物として分離する（該当群では 76.7% が同姓同名の多い名前で、他の群は 14~17% である）。

ORCID（研究者が自ら登録する国際的な識別番号）の状態は良く、383 名のうち 368 名が一つの氏名表記だけに対応していた。そこで ORCID を主な手がかりとし、ORCID を持たない著者は姓と名の頭文字で名寄せした。ORCID 保有者を正解として誤り率を実測すると、別人を同一人物とする誤りが 4.3%、同一人物を分けてしまう誤りが 1.0% だった。ただし ORCID 保有者はフルネームが記録された層に偏っており、頭文字しか分からない著者では誤り率がこれより悪い可能性がある。頭文字しかなく ORCID もない 154 名は目視確認に回す。

4.4 組織を横断して研究する著者を 21 名検出した

たとえば Tomohiko Jimbo 氏は未来創成センターと豊田中央研究所の双方に、Norihito Mizoshita 氏は AISIN IMRA（日本）と豊田中央研究所の双方に論文がある。この 21 名（うち 12 名は ORCID で裏付けが取れている）は、先生が挙げられた「どのようなチーム構造が良い研究成果につながるか」を分析する材料になり得る。ただし今は検出できたところまでで、分析の設計は以下の判断が定まってからになる。

5 判断を仰ぎたい事項

一つめ 分析の対象期間 対象期間を、未来創成センターと豊田中央研究所が揃う 2018 年以降に限るか、全期間とするかを決めたい。2018 年以降に限ると、AISIN IMRA 米国法人の 8 割を落とすことになる。全期間とする場合も、2000 年より前は Web of Science で補える分が 121 件と薄い。ただし、ご指示のあった hot streak のようなキャリア分析には 10 年未満では足りない。キャリアを追うのであれば全期間を提案する。

二つめ 主として用いるデータ 主として用いるデータを、裏付けの取れる割合が 30.0~62.9% の受領リストとするか、独自に構築したデータベースとするかを決めたい。**独自構築のデータベースを提案する**。トヨタ自身の公表情報に基づいており、誤り率も実測できているためである。ただし収録範囲は三組織に限られる。年代の偏りをどう扱うかは一つめの判断しだいである。

三つめ 対象とする組織の範囲 対象を三組織からどこまで広げるかも決めたい。トヨタ関連とみなしうる組織を Web of Science で引くと、豊田工業大学 6,295 件、デンソー 1,457 件、Toyota Research Institute 658 件、JTEKT 279 件、Toyota Motor Europe 278 件、豊田自動織機 127 件などが該当する。このうち豊田工業大学は教育研究機関であり、企業内の研究を扱う本研究の趣旨から外れるため、除外を提案する。残りは第 2 節と同じ機関名検索で回収できる。まずは現在の三組織で分析を始め、必要に応じて広げることを提案する。

6 今後の計画

所属情報は、同一の組織が住所付きの正式名称と略称とで別々に記録されている。まず表記を揃えて組織ごとに集計できる状態にし、独自データベースを基準として受領リストの精度を数値で示す。対象期間は一つめの判断で絞り込み、機関名検索の範囲は三つめの判断に応じて広げる。以上の三点が定まってから、指標計算の設計に入る。第 4.2 節の検証の詳細は別途レポートに、データと処理手順は非公開リポジトリにまとめている。