

トヨタ関連企業 研究者データベースの構築状況

伊倉涼介

2026 年 8 月 17 日

1 本報告について

「誰が、どの論文を、誰と書いたのか」を網羅したデータベースは、本共同研究 Science of Science の分析課題の前提となる。本報告ではその構築状況と分かった事項をまとめて報告する。

2 データベースの構築状況

トヨタの三組織の公式サイトから論文一覧 919 件を自動取得し、うち 852 件（92.7%）を OpenAlex に対応づけた（内訳は表 1。AISIN IMRA は日本法人と米国法人で別サイト）。

表 1 公式サイトから収集した論文と OpenAlex への対応づけ状況

収集元	収集件数	対応づけ済	対応率
豊田中央研究所	355	352	99.2%
AISIN IMRA（米国）	313	292	93.3%
トヨタ自動車未来創成センター	154	131	85.1%
AISIN IMRA（日本）	97	77	79.4%
合計	919	852	92.7%

DOI がある論文は完全一致で、ない論文はタイトルの類似度で対応づけた。文字列一致だけでは誤同定が起こりうるため、判断のつかない 10 件を目視で確認したところ、9 件は同一論文であったが、1 件は掲載誌も出版年も異なる別論文であったため取り消した（表の 852 件は取消後）。対応づかなかった 67 件のうち 66 件は DOI を持たず、OpenAlex 未収録と見られる。

公式サイトに一覧のない AISIN IMRA 欧州法人は、Web of Science（大阪大学が契約する商用の文献データベース）の機関名検索で 25 件を得た。同じ検索は米国法人とアイシン精機で 833 件を返し、うち 683 件は公式サイトに掲載がなかった。機関名検索は公式サイトの掲載漏れを補う手段になる。

被引用 24,786 件と参考文献 27,052 件も取得し、指標計算に使える。著者を研究者単位にまとめ直すと 1,249 名で、うち 1,134 名（90.8%）の所属が判明し、574 名はトヨタ関連企業への所属を確認できた。

3 使用したデータベースとその使い分け

構築には四つの外部データベースを用いており、その分担は一つの判断から導かれている。**著者を名前で検索するより、論文から引く方が安全である**という判断である。著者名で検索すると同姓同名が必ず混ざり、名前だけを手がかりにする限りこの曖昧さは解消できない。一方、論文は DOI で一意に定まる。どの論文かが確定していれば、そこから著者名や所属を取り出しても人物の取り違えは起きない。すなわち「この人物は誰か」という難しい問いを、「この論文の著者は誰か」という確実に答えられる問いに置き換えている。

3.1 OpenAlex（無料） 論文の同定と指標計算の土台

OpenAlex からは、論文の同定と、指標計算の土台になるデータ（被引用、参考文献、分野分類）を取る。一方で著者に振られた識別番号は使わない。同姓同名の別人が一つの番号にまとめられているため、その実例は第 4.3 節に述べる。無料枠は 1 日 1,000 回の取得に限られるが、1 回で 50 件をまとめて取れるため実質 1 日 5 万件に当たり、今回の規模には足りる。

3.2 Crossref（無料） 著者名と ORCID の補完

Crossref は著者名と ORCID を補う。AISIN IMRA 米国法人の 313 件は公式サイトに著者名の記載が一切なかったため、ここで埋めた。ORCID は 383 名分を得た。第 4.3 節に述べるとおり、著者に紐づく識別子のうち信頼できるのはこれだけである。弱点は所属情報にある。Crossref が所属を持っていた論文は 34.5% にとどまる。出版社が登録した場合しか入らないためである。この不足を埋めるのが Scopus である。

3.3 Scopus（大阪大学の契約） 論文を経由した所属の取得

Scopus からは著者の所属を取る。ここには方針を変えた経緯があり、それ自体が本節冒頭の判断の裏づけになっている。当初は著者を名前で検索し、その著者に紐づく所属を直接得るつもりであったが、二つの理由で断念した。一つは、ORCID による検索が試した 6 名すべてで 0 件だったことである。Scopus 側に ORCID がほとんど登録されていない。もう一つは、名前での検索が同姓同名を排除できないことである。「Suzuki」という姓では 45,844 件が該当し、名前だけでは一人に絞り込めない。

そこで、論文から所属を引く方式に切り替えた。どの論文かは確定しているため、取り違えは起きない。結果として所属が分かる論文の割合は 34.5% から 96.1% へ上がり、Scopus だけが所属を持っていた論文も 394 件あった。第 2 節の 1,134 名の所属が判明したという結果は、この方式によるものである。

3.4 Web of Science（大阪大学の契約） 機関単位の探索

Web of Science は他の三つと違い、機関を単位に引く。返ってくるデータに所属の欄がないため、個々の論文について著者の所属を確かめる用途には使えない。代わりに機関名での絞り込みが効くので、機関単位で論文を洗い出す用途に限定している。第 2 節で述べた欧州法人の回収と、公式サイトの掲載漏れの補完がこれにあたる。予備的な検証では著者名と機関名の組み合わせを所属の間接証拠に使えるかを試したが、Scopus が見つけられなかった所属を 1 件も新規発見しなかったため、この用途からは外した。

なお費用について、OpenAlex と Crossref は無料の範囲に収まり、Scopus と Web of Science は大阪大学の契約の範囲にある。追加の費用は発生しない。

4 構築を通じて分かった事項

4.1 収録している年代がサイトによって大きく異なる

出版年が 2018 年以降の割合は、未来創成センター 98.5%、豊田中央研究所 99.4% に対し、AISIN IMRA 米国法人 17.8%（中央値 2006 年、292 件中 62 件は 2000 年より前）、日本法人 51.9%、全体 67.0% である。期間の取り方によって、どの組織のデータがどれだけ残るかが変わる。

4.2 受領した著者リストは裏付けの取れる割合が低い

受領した著者リスト（Sota Hayashi 氏より 9,429 名分、OpenAlex 由来）の 100 名を Scopus（商用の文献データベース）と Web of Science で照合したところ、裏付けの取れた割合は異常なキャリア長の群 30.0%、「トヨタ自

動車のスイス法人」と登録された組織の群 48.6%、対照群 62.9% であった。スイス法人の群の 11 名 (31.4%) は実際には東京大学や三菱総合研究所などに所属し、抽出元によっては母集団に使えない。

4.3 著者の識別番号が信頼できないため、名寄せの誤り率を実測した

受領リストの精度が伸びない原因もここにある。同一人物が複数の表記で現れるため、これを一人に統合する処理 (名寄せ) が最も難しい。受領リストと同じ OpenAlex の著者識別番号は**信頼できない**。同姓同名の別人が一つの番号にまとめられ、「S. Nakamura」は研究歴が 74 年に及ぶ。Web of Science の研究者識別番号も同様に、2022 年発行の番号に 1970 年代の論文が対応づく。研究歴が異常に長い著者はこの集約が原因のため (該当群の 76.7% が同姓同名の多い名前、他は 14~17%)、除外せず複数人物として分離する。

一方 ORCID (研究者が自ら登録する国際的な識別番号) は良好で、383 名のうち 368 名が一つの氏名表記のみに対応した。そこで ORCID を主たる手がかりとし、持たない著者は姓と名の頭文字で名寄せし、ORCID 保有者を正解に誤り率を実測した。別人を同一人物とする誤りが 4.3%、同一人物を分ける誤りが 1.0% である。ただし ORCID 保有者はフルネームが記録された層に偏り、頭文字のみの著者では誤り率がこれより悪い可能性がある。頭文字しかなく ORCID もない 154 名は目視確認に回す。

4.4 組織を横断して研究する著者を 21 名検出した

たとえば Tomohiko Jimbo 氏は未来創成センターと豊田中央研究所の双方に、Norihito Mizoshita 氏は AISIN IMRA (日本) と豊田中央研究所の双方に論文がある。これら 21 名 (うち 12 名は ORCID で裏付け) は、先生が挙げられた「どのようなチーム構造が良い研究成果につながるか」の分析対象になり得る。ただし検出までの段階であり、設計は以下の判断に依る。

5 判断を仰ぎたい事項

一つめ 分析の対象期間 対象期間を、未来創成センターと豊田中央研究所が揃う 2018 年以降に限るか全期間とするか決めたい。前者は AISIN IMRA 米国法人の 8 割を失い、後者も Web of Science で補える 2000 年より前が 121 件と薄い。ただしご指示の hot streak のようなキャリア分析に 10 年未満では足りず、キャリアを追うのであれば全期間を提案する。

二つめ 主として用いるデータ 主たるデータを、裏付けの取れる割合が 30.0~62.9% にとどまる受領リストとするか、独自構築のデータベースとするか決めたい。**後者を提案する**。トヨタ自身の公表情報に基づき、誤り率も実測できているためである。ただし収録範囲は三組織に限られ、年代の偏りは一つめの判断に依存する。

三つめ 対象とする組織の範囲 三組織をどこまで広げるかも決めたい。トヨタ関連とみなしうる組織の論文数は、Web of Science で豊田工業大学 6,295 件、デンソー 1,457 件、Toyota Research Institute 658 件、JTEKT 279 件、Toyota Motor Europe 278 件、豊田自動織機 127 件などである。豊田工業大学は教育研究機関であり、企業内研究を扱う本研究の趣旨から外れるため除外を提案する。残りは第 2 節と同じ機関名検索で回収できる。まず現在の三組織で分析を始め、必要に応じて広げることを提案する。

6 今後の計画

所属情報は同一組織が住所付きの正式名称と略称で別々に記録されているため、まず表記を揃えて組織ごとに集計できる状態にし、独自データベースを基準に受領リストの精度を数値で示す。一つめの判断で対象期間を絞り込み、三つめの判断に応じて機関名検索の範囲を広げる。三点が定まってから指標計算の設計に入る。第 4.2 節の検証の詳細は別途レポートに、データと処理手順は非公開リポジトリにまとめている。